


Práctica 2

DETERMINACIÓN DE TIPOS DE ESTRELLAS

1,5 puntos

INTRODUCCIÓN

En astronomía la clasificación de estrellas en tipos permite realizar hipótesis acerca de su dinámica, establecer cómo y cuándo se formaron, su composición y cuál será su evolución y fin. El nombrar a las estrellas como enanas blancas, tipo sol, supergigantes, etc. no es más que una categoría asociada a algunas de esas clasificaciones.



Se propone en este trabajo obtener los tipos de estrellas utilizando técnicas de aprendizaje automático no supervisado. Para lo cual, se tiene un conjunto de datos de 240 estrellas con los siguientes atributos:

- **Temperature:** Temperatura promedio de la superficie en grados K
- **L:** Luminosidad comparada con la del Sol.
- **R:** Radio comparado con la del Sol.
- **A_M:** Magnitud absoluta (brillo aparente de la estrella si estuviera a 10 parsec de distancia)
- **Spectral_Class:** Clasificación espectral: es un valor que identifica la presencia elementos químicos en el espectro de la estrella. Es una secuencia (O, B, A, F, G, K, M) que se asocia a las estrellas desde las más calientes O, hasta las más frías M
- **Color:** Color principal del espectro

CONSIDERACIONES GENERALES

1. Para realizar la práctica, los estudiantes emplearán un repositorio de código en GitHub. Para ello, cada grupo debe crear un repositorio de código privado y agregar como «colaborador» al profesor de prácticas (que indicará a los estudiantes su nombre de usuario en GitHub). Se espera que cada grupo haga un commit semanal del código de la práctica. Esta parte de la práctica se valorará con 0.5 puntos. Además, también habrá que entregar el cuaderno (notebook) final a través de Aula Global.
2. Se proporciona un fichero de datos: “starts_data.csv”

3. Los resultados deben ser reproducibles. Por lo tanto, hay que fijar la semilla de números aleatorios en los lugares adecuados. Se usará como semilla el NIA de uno de los miembros del grupo o bien el número del grupo de prácticas. Si hay que utilizar más semillas se usan números consecutivos al NIA de base.

QUÉ HACER

1. Codificar de manera adecuada (ordinal) las variables categóricas (Color, Clase Espectral). Tener en cuenta que el color está asociado a la cantidad de energía, y algo parecido con la clase espectral.
2. Para facilitar la visualización de los datos y la tarea de clustering en esta práctica, convertiremos previamente los datos a 2 dimensiones, usando PCA con 2 componentes principales. Los algoritmos de clustering se aplicarán directamente sobre esas dos componentes principales obtenidas mediante PCA.
3. Aplicar los tres algoritmos de clustering explicados en clase (K-Means, Hierarchical Clustering/Dendrogramas, DBSCAN), comparando y discutiendo los resultados que se obtienen de ellos.
 - Usar las métricas adecuadas para cada método. Para DBSCAN, se usará la métrica DBCV. Esta métrica no está disponible en scikit-learn, por lo que será necesario encontrar una versión adecuada en la web.
 - Será necesario hacer ajuste de hiper-parámetros de las distintas técnicas (número de clusters para K-medias, número de clusters para los dendrogramas, eps y min_samples para DBSCAN).
 - Para el ajuste de hiper-parámetros de DBSCAN, se pueden utilizar los procedimientos heurísticos asociados a DBSCAN, pero también se pueden probar otros valores de hiper-parámetros, evaluar los clusters resultantes con la métrica DBCV, y seleccionar los mejores.
 - Se puede elegir directamente una función de linkage para los dendrogramas, siempre que se justifique. O bien probar varias, evaluarlas y quedarse con la mejor.
4. A partir de los resultados obtenidos, ¿qué pipeline de clustering, algoritmo, con sus hiperparámetros, recomendaría realizar?
5. La siguiente tabla contiene las clases y atributos asociados a las estrellas que la astronomía utiliza habitualmente. ¿Hay similitudes entre las clases de dicha tabla y los grupos obtenidos en el punto 4? Explicar

Clase	Temperatura	L	R	A_M	Color	Clase Espectral
Enana roja	3.000	$7,0 \cdot 10^{-4}$	$1,0 \cdot 10^{-1}$	+17.5	rojo	K-M
Enana marrón	3.300	$5,5 \cdot 10^{-3}$	$3,5 \cdot 10^{-1}$	+12.5	rojo	M
Enana blanca	14.000	$2,5 \cdot 10^{-3}$	$1,0 \cdot 10^{-2}$	+12.6	blanca	B-G
Estrella en secuencia principal	16.000	$3,2 \cdot 10^4$	4,4	-0.4	blanca-amarilla	B-M
Super gigante	15.000	$3,0 \cdot 10^5$	$5,0 \cdot 10^1$	-6.4	blanca-amarilla	B-M
Hiper gigante	11.000	$3,0 \cdot 10^5$	$1,4 \cdot 10^3$	-9.6	amarilla	B-M

QUÉ ENTREGAR

Entregar un único notebook con:

1. Comparación y discusión de diferentes algoritmos de clustering.
2. Pipeline recomendado para realizar el clustering de los datos.
3. Discusión de la comparación de los grupos obtenidos del punto 3 y los utilizados en astronomía